

BASES DE DATOS ORIENTADAS A COLUMNAS

Mario Julián Mora
mario.mora@u.icesi.edu.co

Mónica Rojas
mmrojas@icesi.edu.co



Unidad 4 – Bases de datos NoSQL

- Su precursor fue Google BigTable
- **BigTable** (column oriented) es un sistema de gestión de base de datos creado por Google distribuido, de alta eficiencia y propietario.



- Tablas multidimensionales
- Se divide en columnas -> tabletas
- Cada tableta 200 Mb
- En cada nodo 100 tabletas

BD ORIENTADAS A COLUMNAS

- Modelo de datos: familia de columnas, esto es, un modelo tabular donde cada fila puede tener una configuración diferente de columnas
 - Guardan datos por columna en vez de las BBDD tradicionales que lo hacen por filas
- Ejemplos: HBase, Hypertable, Cassandra, Riak
- Buenas en:
 - Gestión de tamaño
 - Cargas de escrituras masivas
 - Alta disponibilidad
 - MapReduce



DB ENGINES RANKING

416 systems in ranking, November 2023

Rank			DBMS	Database Model	Score		
Nov 2023	Oct 2023	Nov 2022			Nov 2023	Oct 2023	Nov 2022
1.	1.	1.	Oracle +	Relational, Multi-model i	1277.03	+15.61	+35.34
2.	2.	2.	MySQL +	Relational, Multi-model i	1115.24	-18.07	-90.30
3.	3.	3.	Microsoft SQL Server +	Relational, Multi-model i	911.42	+14.54	-1.09
4.	4.	4.	PostgreSQL +	Relational, Multi-model i	636.86	-1.96	+13.70
5.	5.	5.	MongoDB +	Document, Multi-model i	428.55	-2.87	-49.35
6.	6.	6.	Redis +	Key-value, Multi-model i	160.02	-2.95	-22.03
7.	7.	7.	Elasticsearch	Search engine, Multi-model i	139.62	+2.48	-10.70
8.	8.	8.	IBM Db2	Relational, Multi-model i	136.00	+1.13	-13.56
9.	9.	↑ 10.	SQLite +	Relational	124.58	-0.56	-10.05
10.	10.	↓ 9.	Microsoft Access	Relational	124.49	+0.18	-10.53
11.	11.	↑ 12.	Snowflake +	Relational	121.00	-2.24	+10.84
12.	12.	↓ 11.	Cassandra +	Wide column, Multi-model i	109.17	+0.34	-8.96
13.	13.	13.	MariaDB +	Relational, Multi-model i	102.09	+2.43	-2.82

• <https://db-engines.com/en/ranking>

DB RANKING - WIDE COLUMN

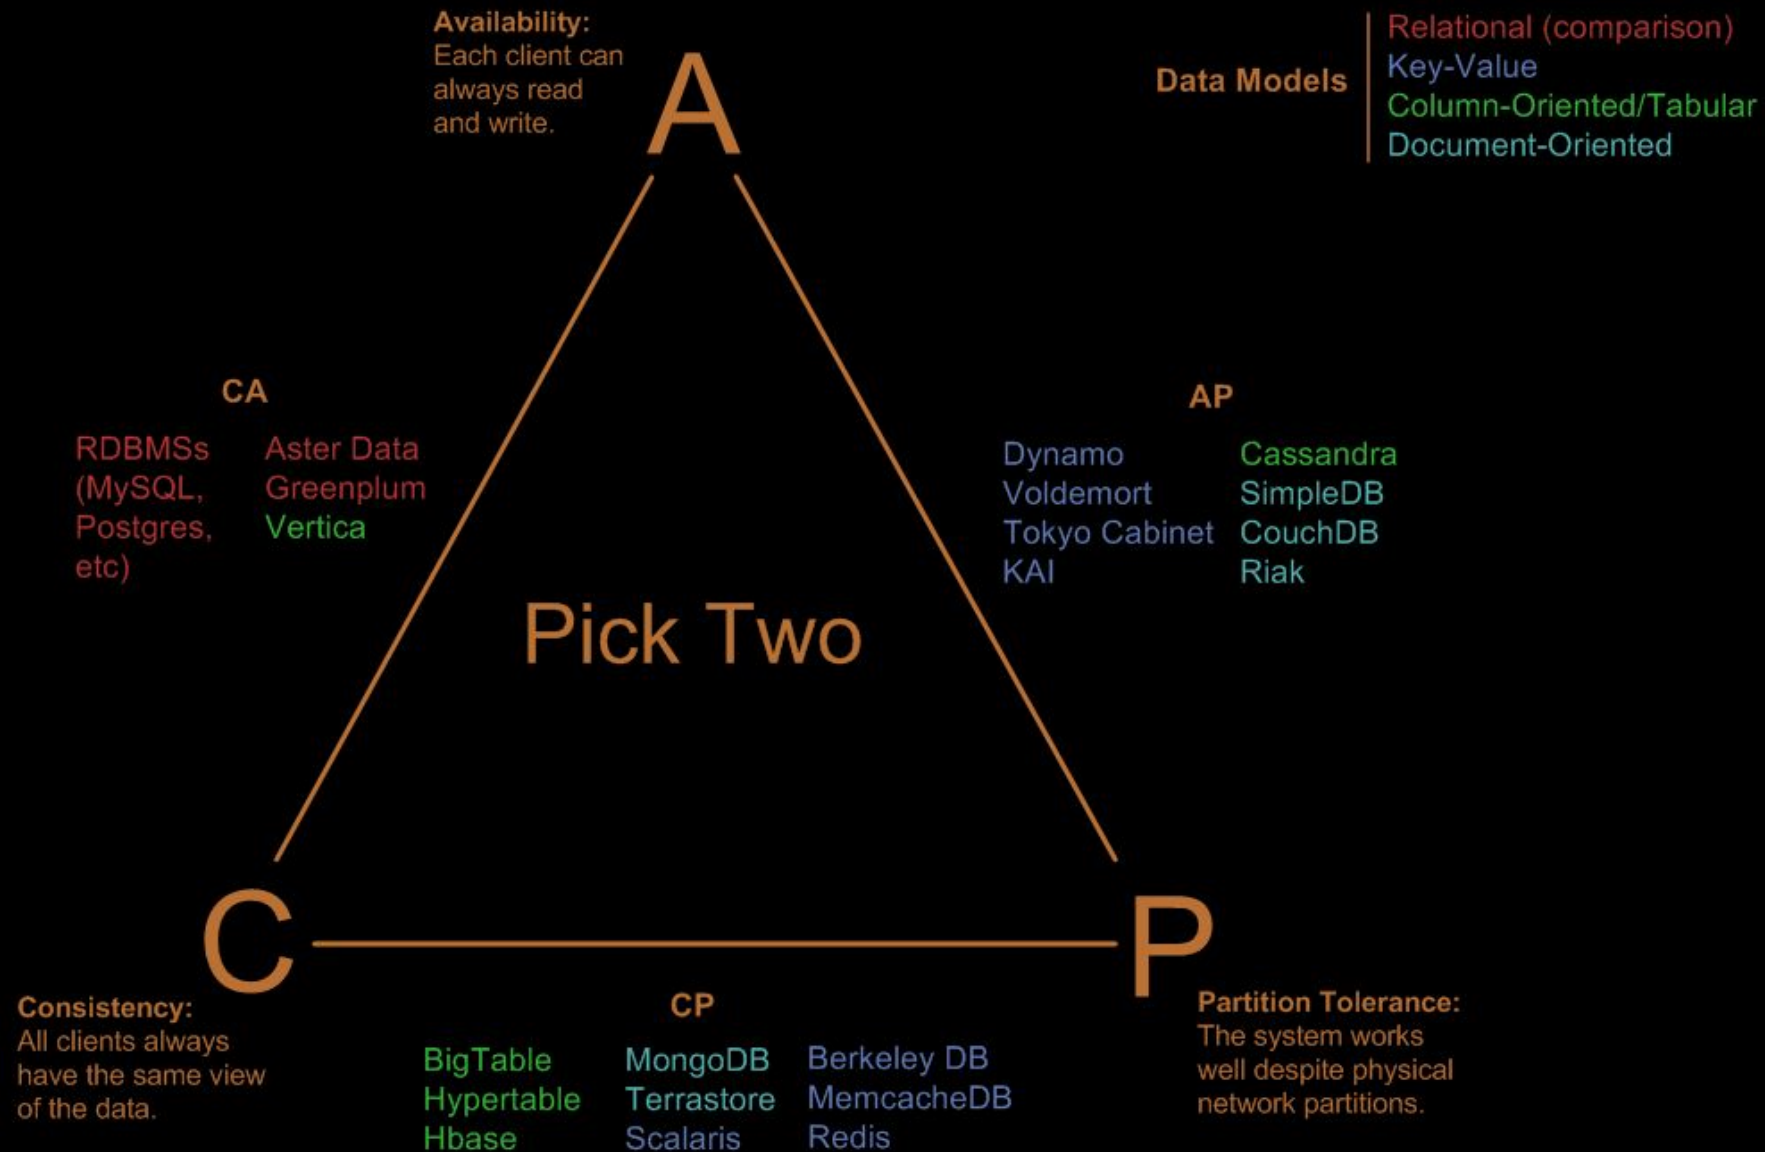
☐ include secondary database models

13 systems in ranking, November 2023

Rank			DBMS	Database Model	Score		
Nov 2023	Oct 2023	Nov 2022			Nov 2023	Oct 2023	Nov 2022
1.	1.	1.	Cassandra +	Wide column, Multi-model i	109.17	+0.34	-8.96
2.	2.	2.	HBase	Wide column	34.16	-0.53	-6.25
3.	3.	3.	Microsoft Azure Cosmos DB +	Multi-model i	34.11	-0.18	-5.64
4.	4.	4.	Datastax Enterprise +	Wide column, Multi-model i	7.26	+0.48	-1.42
5.	5.	↑ 8.	ScyllaDB +	Wide column, Multi-model i	6.56	+0.38	+1.61
6.	6.	↓ 5.	Microsoft Azure Table Storage	Wide column	6.08	+0.31	+0.06
7.	7.	↓ 6.	Google Cloud Bigtable	Multi-model i	4.26	-0.35	-0.97
8.	8.	↓ 7.	Accumulo	Wide column	4.14	-0.47	-0.84
9.	9.	9.	HPE Ezmeral Data Fabric	Multi-model i	1.24	-0.07	-0.02
10.	10.	10.	Amazon Keyspaces	Wide column	0.98	-0.13	+0.21
11.	11.	11.	Elassandra	Wide column, Multi-model i	0.52	-0.01	-0.05
12.	12.	12.	Alibaba Cloud Table Store	Wide column	0.26	+0.04	-0.07
13.	13.	13.	SWC-DB	Wide column, Multi-model i	0.05	+0.04	-0.02

• <https://db-engines.com/en/ranking>

Visual Guide to NoSQL Systems



MODELO DE DATOS

- Es una tripleta (nombre de columna, valor, marca de tiempo)

Column		
name: byte[]	value: byte[]	clock : IClock

- Cada columna en Cassandra posee una marca horaria, la cual graba la última fecha en que la columna fue actualizada, la marca es de las columnas y no de los registros. Este dato no puede consultarse, se usa únicamente para resolución de conflictos en el servidor.

MODELO DE DATOS

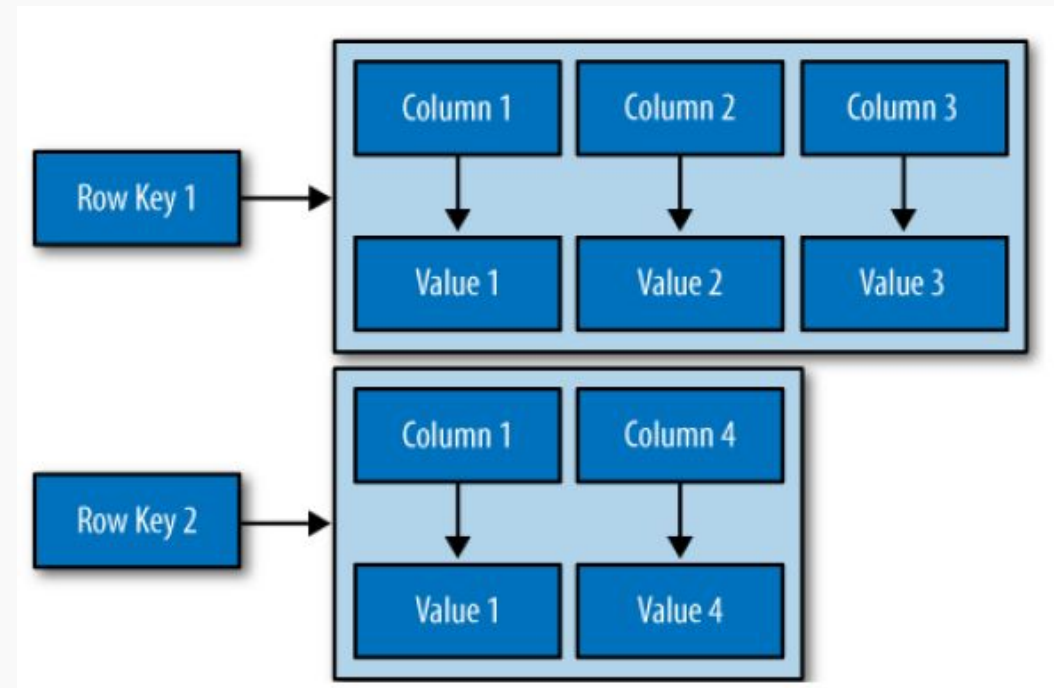
- Cassandra define una familia de columnas para asociar datos similares.
- Por ejemplo, se puede tener una familia de columnas llamada Usuario, otra llamada Hotel, otra llamada Registro y muchas más.
- Una familia de columnas es análoga a una tabla en el modelo relacional.

MODELO DE DATOS

No se necesita almacenar un valor para cada columna si no se tiene información.

Por ejemplo, algunas personas tienen un segundo número de teléfono y otras no.

En vez de colocar NULL para los valores que no conocemos, lo cual gasta espacio, simplemente no se tiene en cuenta la columna para ese registro. Con esto se tiene una estructura de arreglos multidimensional como esta:




CUANDO UTILIZARLAS

- Soluciones de tipo analítico

- ¿Por qué?

Porque al tener almacenada la información de las columnas junta, se reduce notablemente los requisitos globales de E/S del disco, y disminuye el volumen de datos que hay que cargar desde él.



APACHE CASSANDRA



- Es un almacén altamente escalable, eventualmente consistente y distribuido de estructuras clave-valor.
 - Iniciado por Facebook
 - Código abierto
 - Proyecto apache
 - Licencia: Apache License 2.0
 - Escrito en Java
 - Multiplataforma
 - Versión actual: 3.11(2019-02-11)
 - Web: <http://cassandra.apache.org/download/>
 - Documentación:
https://docs.datastax.com/en/landing_page/doc/landing_page/cassandra.html



VENTAJAS CASSANDRA


Cassandra está desarrollada para ser un **servidor distribuido**, pero puede también ejecutarse como un nodo simple:

- Escalabilidad horizontal (añade nuevo hardware cuando sea preciso)
- Rápidas respuestas aunque la demanda crezca
- Elevadas velocidades de escritura para gestionar volúmenes de datos incrementales
- Almacenamiento distribuido
- Capacidad de cambiar la estructura de datos cuando los usuarios demandan más funcionalidad
- Una API sencilla y limpia para tu lenguaje de programación favorito
- Detección automática de fallos
- No hay un punto de fallo único (cada nodo conoce de los otros)
- Descentralizada
- Tolerante a fallos
- Permite el uso de Hadoop para implementar Map Reduce



DESVENTAJAS CASSANDRA

- Hay algunas desventajas que un sistema de almacenamiento tan escalable ofrece en contrapartida:
 - No hay joins (a cambio de más velocidad)
 - No permite ordenar resultados en tiempo de consulta
 - No tiene SQL
 - Pero desde la versión 0.8 se tiene CQL




RING, CLÚSTER Y EL PROTOCOLO GOSSIP

- Cassandra usa un protocolo Gossip para permitir comunicación dentro de un ring, de tal modo que cada nodo sabe de otros nodos
 - Permite soportar descentralización y tolerancia a la partición
- Cassandra está diseñada para ser distribuida en varias máquinas que aparecen como un único nodo.
 - La estructura más externa de Cassandra es el clúster o ring
 - Un nodo tiene una réplica para diferentes rangos de datos, si algo va mal una réplica puede responder
 - El parámetro `replication_factor` en la creación de un KeySpace indica cuántas máquinas en el clúster recibirán copias de los mismos datos.



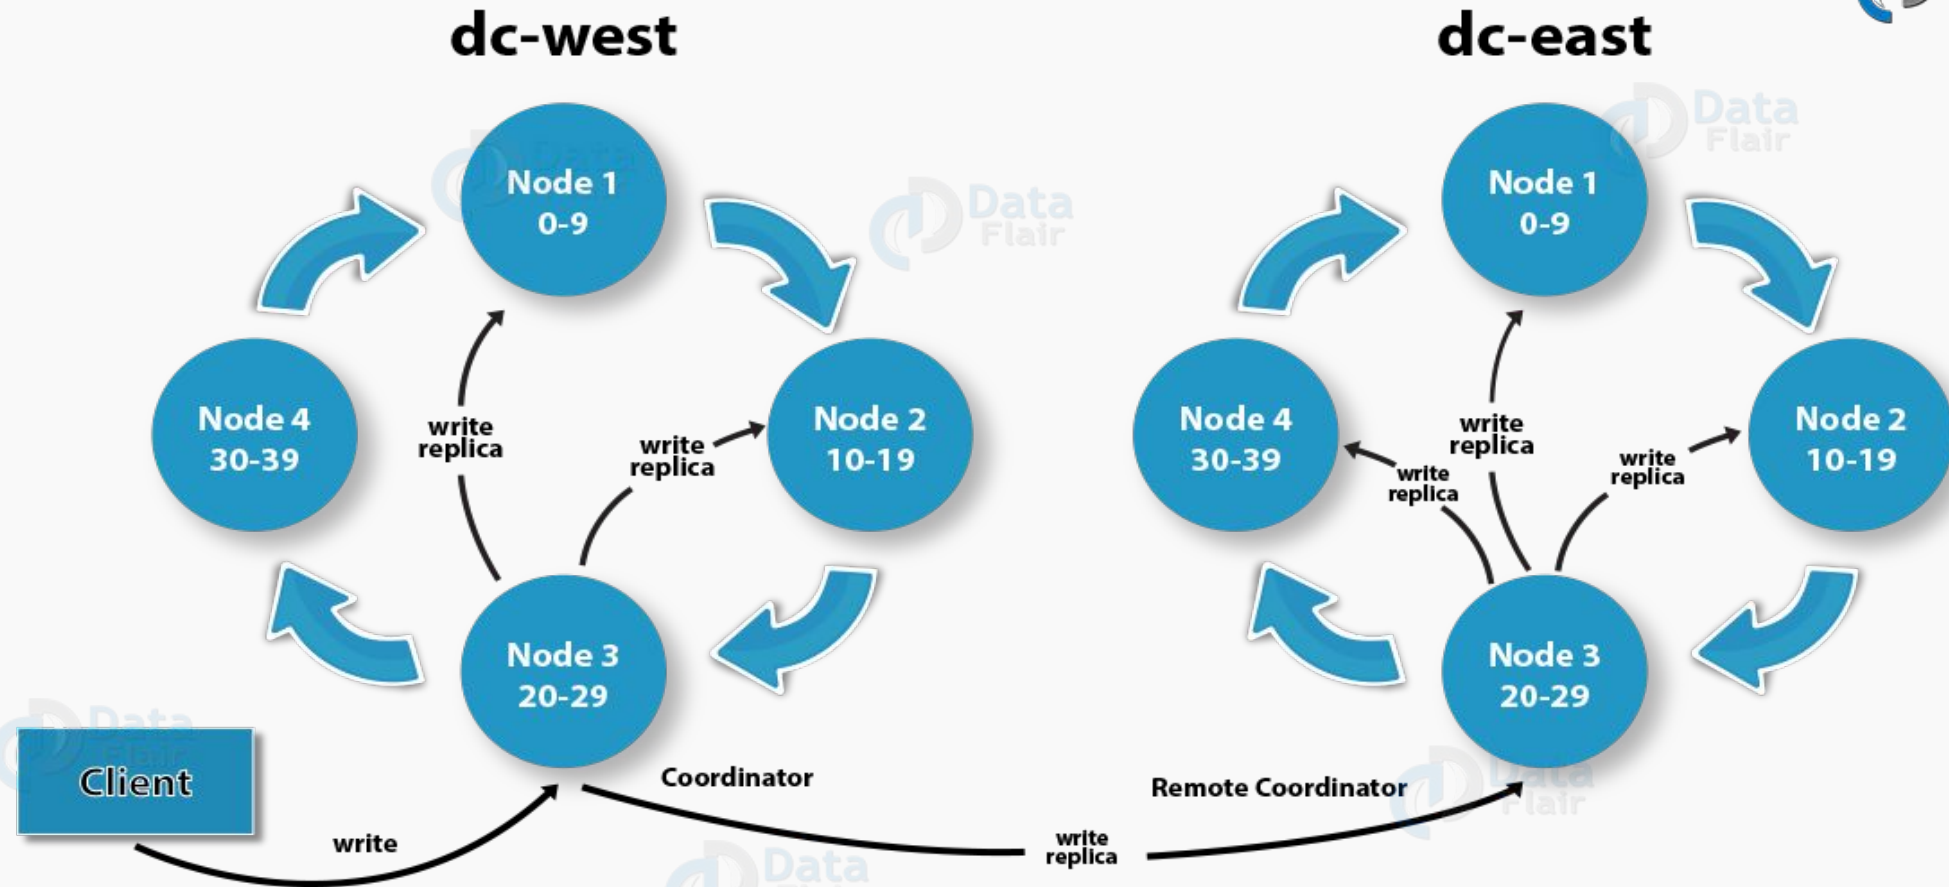
CASSANDRA ARCHITECTURE- SIMPLE STRATEGY

Guarda las copias en un solo datacenter.



CASSANDRA ARCHITECTURE- NETWORK TOPOLOGY STRATEGY

Se utiliza para diferentes datacenters.





TEOREMA CAP EN CASSANDRA

- Centradas en disponibilidad y tolerancia a fallos
- Permiten Consistencia Eventual
(Donde “eventual” significa milisegundos)

- Cassandra es AP:

“To primarily support Availability and Partition Tolerance, your system may return inaccurate data, but the system will always be available, even in the face of network partitioning”

MODELO DE DATOS EN CASSANDRA

- Diseñado para datos distribuidos de modo escalable: sacrifica ACID por ventajas en rendimiento, disponibilidad y gestión operacional
- Los modelos que se crean son desnormalizados:
 - Se suele crear una column family por cada consulta (query) a realizar
 - Varias filas en un column family suelen dar respuesta a una consulta
- Los conceptos básicos son:
 - **Clúster:** son las máquinas que componen una instancia de Cassandra.
(Pueden contener varios Keyspaces)
 - **Keyspace:** espacio de nombres para un conjunto de ColumFamily, asociado a una aplicación.
(Suele asociarse con una BD en el modelo relacional)
 - **ColumFamily:** contienen varias columnas
(Suelen asociarse con una tabla en el modelo relacional)
 - **SuperColumn:** columnas que ellas mismas tienen sub-columnas
 - **Column:** compuestas de un nombre, valor y timestamp




COLUMN

- Una **columna** es un par nombre-valor que también contiene un timestamp
 - Los nombres y columnas son arrays de bytes
 - El timestamp registra la última vez que una columna es accedida
 - Unidad atómica

- `name:value:timestamp`
- `Email:monroj@icesi.edu.co:123456789`

- Ejemplo en JSON:

```
{  
  "name": "Email",  
  "value": "monroj@icesi.edu.co",  
  "timestamp": 123456789  
}
```



FILA

- Agregación de columnas con un nombre para referenciarlo.
- Equivale a la fila en el modelo relacional.

Nombre columnas

9871r,,,12xy	Nombre_usuario	Fecha_registro	Telefono
	MonicaRojas	2018-04-15	5468975

KEY Valores

The diagram illustrates a table structure with a key and values. The key is '9871r,,,12xy' and the values are 'MonicaRojas', '2018-04-15', and '5468975'. Arrows point from 'Nombre columnas' to the column headers and from 'Valores' to the data cells. An arrow points from 'KEY' to the key cell.

FILA

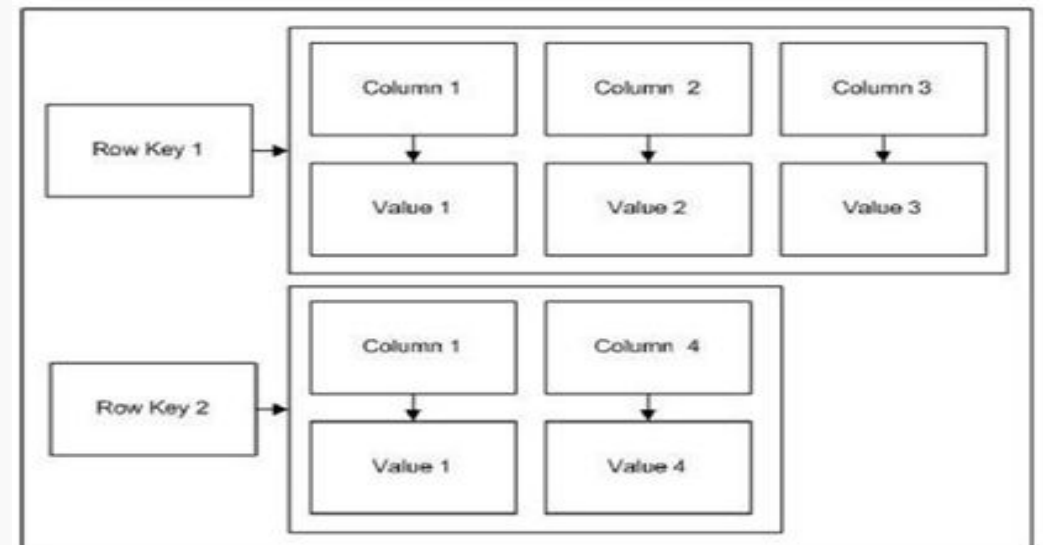
- Tiene un ROW Key, o clave primaria de las filas.

Dos partes:

- Partition key (de particionado): las filas con el mismo valor de clave de particionado se almacenan en la misma partición del disco (físicamente juntas).
- Clustering key (de agrupamiento): determina el orden físico en el que se almacenan las filas.

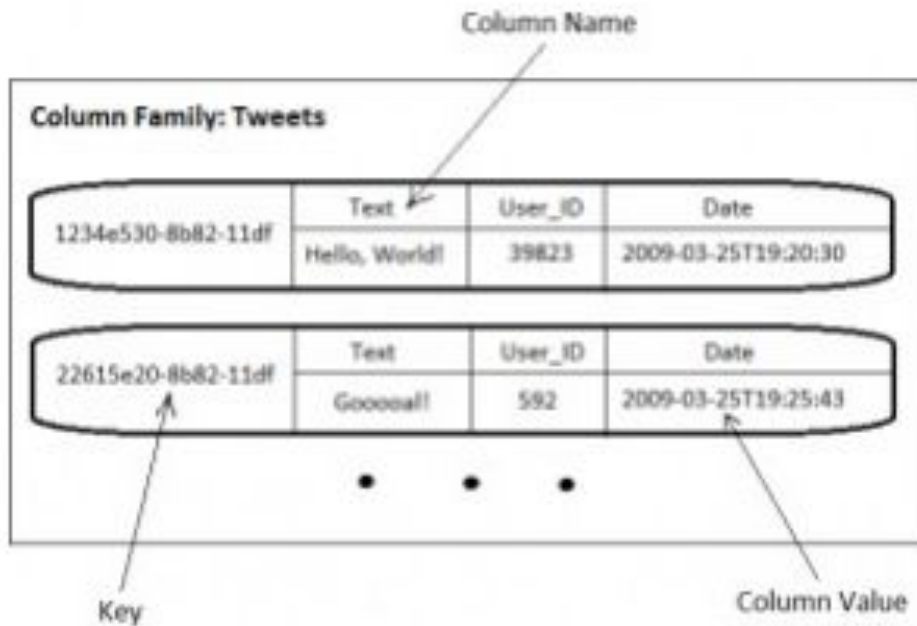
COLUMN FAMILY

- Es un contenedor de columnas
 - Análogo al concepto de tabla en RDBMS
- Contiene una lista ordenada de columnas
 - Cuando se crea de manera configurativa una familia de columnas se indica cómo se ordenarán las columnas de cada fila.
 - ASCII, UTF-8, Long, UUID
- Cada familia de columnas se guarda en una partición, y la partición está ordenado por la clustering key.
- Una familia de columnas tiene un ... conjunto de filas con un conjunto de ... columnas similar pero no idéntico



KEYSPACES

Un espacio de claves o KeySpace es un esquema de alto nivel que contiene familias de columnas.



Column Family “Entradas en Twitter: tweets”:

RDBS VS. KEYSPACE

blog relational database

users table

user_id	username	state
1	jbellis	TX
2	dhutch	CA
3	egilmore	NULL

blog table

blog_id	user_id	blog_entry	categoryid
101	1	Today I ...	3
102	2	I am ...	2
103	1	This is ...	3

subscriber table

subscriber	blogger	row_id
1	2	1
2	1	2
1	3	3

category table

category	categoryid
sports	1
fashion	2
technology	3

blog keyspace

users

jbellis	name	state
	jonathan	TX
dhutch	name	state
	daria	CA
egilmore	name	
	eric	

blog entries

92dbeb5	body	user*	category*
	Today I ...	jbellis	tech
d418a66	body	user	category
	I am ...	dhutch	fashion
6a0b483	body	user	category
	This is ...	egilmore	sports

* = secondary indexes

subscribes_to

jbellis	dhutch	egilmore
dhutch	jbellis	
egilmore	jbellis	dhutch

subscribers_of

jbellis	dhutch	egilmore
dhutch	egilmore	dhutch
egilmore	jbellis	

time_ordered_blogs_by_user


jbellis	1289847840615
	92dbeb5
dhutch	1289847840615
	d418a66
egilmore	1289847844275
	6a0b483

COMPARACIÓN

Modelo Relacional	Modelo Cassandra
Base de datos	Keyspace
Tabla	Column Family (CF)
Primary key	Row key
Atributo	Column name /key
Valor	Column value

INSTALACIÓN DE CASSANDRA

- Documentación en:
https://cassandra.apache.org/doc/latest/cassandra/getting_started/index.html
- Requisitos:
 - Java.
 - Python.
- Las últimas versiones estables disponibles en:
 - <http://cassandra.apache.org/download/>



AMBIENTES ALTERNATIVOS

Instalación versión de Datastax:

<https://www.datastax.com/blog/getting-started-apache-cassandra-windows-easy-way>

Datastax Community Edition (Win)

<https://datastax-community-edition.software.informer.com/2.2/>

En línea, creando un espacio en Astra:

<https://astra.datastax.com/register>

Pasos para la configuración [\[link\]](#)



Cassandra


Data Definition Command

KEYSPACE


- A. CREATE KEYSPACE
- B. USE
- C. ALTER KEYSPACE
- D. DROP KEYSPACE
- E. CREATE TABLE
- F. ALTER TABLE
- G. TRUNCATE TABLE
- H. DROP TABLE
- I. CREATE INDEX
- J. DROP INDEX

CREACIÓN DE UN KEYSPACE

SimpleStrategy: se define cuando deseamos que los datos se almacenen en un solo data center.



NetworkTopologyStrategy: se define si se planea desplegar el cluster en múltiples data centers.



CREAR Y USAR UN KEYSPACE

CREATE KEYSPACE prueba **WITH** replication =
{'class': 'SimpleStrategy', 'replication_factor': '1'};

Nombre del keyspace

Define la estrategia de replicación (SimpleStrategy o NetworkTopologyStrategy)

Número de réplicas de los datos en múltiples nodos, solo si es SimpleStrategy.

USE prueba;

```
For more details, please visit https://support.apple.com/kb/HT208050.  
[$ cqlsh  
Connected to Test Cluster at 127.0.0.1:9042.  
[cqlsh 5.0.1 | Cassandra 3.11.10 | CQL spec 3.4.4 | Native protocol v4]  
Use HELP for help.  
cqlsh> CREATE KEYSPACE prueba WITH replication  
[ ... = {'class': 'SimpleStrategy', 'replication_factor': '1'};  
[cqlsh> USE prueba;
```

DESCRIBE KEYSAPACES; //Muestra los keyspaces disponibles en la base de datos.

CREACIÓN DE TABLAS (FAMILIAS DE COLUMNAS)

- En CQL 3.x, las familias de columnas se crean con una sintaxis de creación de tablas (CREATE TABLE) similar a SQL.
- Una tabla debe tener al menos una clave primaria.
- Una clave primaria identifica la ubicación y el orden de los datos almacenados. La clave principal se define cuando se crea la tabla y no se puede modificar.

```
CREATE TABLE [IF NOT EXISTS] [keyspace_name.]table_name (  
    column_definition [, ...]  
    PRIMARY KEY (column_name [, column_name ...])  
[WITH table_options  
    | CLUSTERING ORDER BY (clustering_column_name order)]  
    | ID = 'table_hash_tag'  
  
    | COMPACT STORAGE]
```

TIPOS DE DATOS

Tipo de blob

Tipo de datos	Descripción
blob	Representa bytes arbitrarios.

Tipo booleano

Tipo de datos	Descripción
boolean	Representa true o bien false.

Tipos relacionados con el tiempo

Tipo de datos	Descripción
timestamp	Representa una marca temporal.
timeuuid	Representa un objeto UUID versión 1 .

Tipos numéricos

Tipo de datos	Descripción
bigint	Representa un largo firmado de 64 bits.
counter	Representa un contador de enteros firmado de 64 bits. Para obtener más información, consulte Counters .
decimal	Representa un decimal de precisión variable.
double	Representa un punto flotante IEEE 754 de 64 bits.
float	Representa un punto flotante IEEE 754 de 32 bits.
int	Representa un int firmado de 32 bits.
varint	Representa un entero de precisión arbitraria.

Tipos de cadena

Tipo de datos	Descripción
ascii	Representa una cadena de caracteres ASCII.
text	Representa una cadena de caracteres UTF-8.
varchar	Representa una cadena con codificación UTF-8 (<code>varchar</code> es un alias para <code>text</code>).

EJEMPLO

Crear la familia de columnas con el nombre USERS, con clave primaria id.

CREATE TABLE users (

id text,
firstname text,
lastname text,
year int,
height float,
phone int,

PRIMARY KEY (id));

Partition key

- En este caso, al ser el id del usuario único, todas las particiones de la tabla contienen una sola fila.
- No hay clustering key.

partición 1	001	Pedrito	Castro	1.57	1972	Pedrito@hotmail.com
partición 2	002	Maria	Fernandez	1.72	1980	maria@correo.com
partición 3	003	Manuela	Rojas	1.62	1980	manuela@correo.com

EJEMPLO 2

Crear la familia de columnas con el nombre USERS_YEAR, con clave primaria year.

CREATE TABLE users_year (
id text,
firstname text,
lastname text,
year int,
height float,
phone int,
Email text,

PRIMARY KEY (year));

Partition key

- Las réplicas de las filas de una partición se encuentran físicamente juntas.
- Las diferentes particiones de las filas de una familia de columnas (tabla) pueden residir físicamente en nodos diferentes

partición 1

1972	Pedrito	Castro	1.57	001	Pedrito@hotmail.com
------	---------	--------	------	-----	---------------------

partición 2

1980	Maria	Fernandez	1.72	002	maria@correo.com
1980	Manuela	Rojas	1.62	003	manuela@correo.com

REVISAR LA ESTRUCTURA DE LA TABLA

1. DESCRIBE users;

```
cqlsh:prueba> describe users;

CREATE TABLE prueba.users (
  id text PRIMARY KEY,
  firstname text,
  height float,
  lastname text,
  phone int,
  year int
) WITH additional_write_policy = '99p'
  AND bloom_filter_fp_chance = 0.01
  AND caching = {'keys': 'ALL', 'rows_per_partition': 'NONE'}
  AND cdc = false
  AND comment = ''
  AND compaction = {'class': 'org.apache.cassandra.db.compaction.SizeTieredCompactionStrategy', 'max_threshold': '32', 'min_threshold': '4'}
  AND compression = {'chunk_length_in_kb': '16', 'class': 'org.apache.cassandra.io.compress.LZ4Compressor'}
  AND crc_check_chance = 1.0
  AND default_time_to_live = 0
  AND extensions = {}
  AND gc_grace_seconds = 864000
  AND max_index_interval = 2048
  AND memtable_flush_period_in_ms = 0
  AND min_index_interval = 128
  AND read_repair = 'BLOCKING'
  AND speculative_retry = '99p';
cqlsh:prueba>
```

AGREGAR NUEVO CAMPO A LA TABLA

1. **ALTER TABLE** users **ADD** email text;
2. **DESCRIBE** users;

Consulta al diccionario de datos:

```
SELECT * from system_schema.tables  
WHERE keyspace_name='practica' ;
```

```
cqlsh:prueba> SELECT table_name from system_schema.tables WHERE keyspace_name='prueba' ;  
  
table_name  
-----  
student  
users  
users2  
users3  
users4  
  
(5 rows)
```

```
DESCRIBE TABLES; //Muestra los tablas que hay en el keyspace actual
```


MODIFICACIÓN

Para modificar tablas o keyspaces se utiliza la cláusula ALTER.

- Modificación de keyspace:

```
ALTER KEYSPACE BD_tienda_online WITH REPLICATION = { 'class' : 'SimpleStrategy',  
'replication_factor' : 2 };
```

- Modificación de tablas:

```
ALTER TABLE users ADD apellido1 int;
```

```
ALTER TABLE users ALTER apellido1 TYPE text;
```

```
ALTER TABLE users DROP apellido1;
```

- El ALTER también se puede utilizar para modificar usuarios o tipos definidos.

BORRADO

Para borrar cualquier elemento de la base de datos (tabla, índice, usuario...) se utiliza la cláusula DROP. Ejemplos:

DROP TABLE usuario;


DROP INDEX indiceNombreUsuario;

() DROP TRIGGER disparador1X;

DROP TYPE tipo2Y;

DROP KEYSPACE prueba;

...



CQL Data Manipulation Commands

01

INSERT

02

UPDATE

03

DELETE

04

BATCH




INSERTAR FILAS

supported



INSERT INTO...



()

INSERTAR FILAS

Ejemplo:

```
INSERT INTO users(id, firstname, lastname, height, year, email) VALUES ('001', 'Pedrito', 'Castro', 1.57, 1972, 'Pedrito@hotmail.com');
```

[]

```
INSERT INTO users(id, firstname, lastname, height, year, email) VALUES ('002', 'Maria', 'Fernandez', 1.72, 1980, 'maria@correo.com');
```

Ver la tabla con todos los datos: `SELECT * FROM users;`

Inserte los datos de 5 usuarios más

```
INSERT INTO users(id, firstname, lastname, height, year, email) VALUES ('003', 'Manuela', 'Rojas', 1.62, 1980, 'manuela123@yahoo.com');
```

```
INSERT INTO users(id, firstname, phone, year) VALUES ('004', 'Camila', 324228, 1978);
```

USING TTL

Esta opción permite realizar un insert por tiempo limitado, dicho tiempo se define en segundos y en el momento en el que se cumpla ese tiempo, Cassandra automáticamente eliminará ese dato introducido.

`INSERT INTO users(id, firstname, phone, email) VALUES ('012', 'John', 798221, 'john2018@outlook.com') USING TTL 600;`

id	apellido	edad	email	estatura	nombre	telefono
004	null	null	null	null	Camila	324228
012	null	null	john2018@outlook.com	null	John	798221
002	Fernandez	null	maria@correo.com	1.72	Maria	3156745
001	Castro	47	Pedrito@hotmail.com	1.57	Pedrito	null
003	null	null	manuela123@yahoo.com	null	Manuela	235644

MODELAMIENTO

Objetivos:

Regla 1: Distribuir los datos por todo el clúster

- Es deseable que cada nodo del clúster tenga un volumen de datos similar (equilibrio).
- Como las filas se distribuyen en base a la **partition key** es conveniente escoger una clave primaria adecuada.

Regla 2: Minimizar el número de particiones a leer

- Las particiones son grupos de filas que comparten la misma partition key.
- Cuantas menos particiones tengan que ser leídas, más rápida será la lectura.

<https://www.datastax.com/blog/basic-rules-cassandra-data-modeling>

ACTUALIZAR UN VALOR EN LA TABLA

Ejemplo:

```
UPDATE users SET email='Pedrito123@gmail.com' WHERE id='001';
```


ver cambio en la tabla:

```
SELECT * FROM users;
```

id	apellido	edad	email	estatura	nombre	telefono
004	null	null	null	null	Camila	324228
012	null	null	john2018@outlook.com	null	John	798221
002	Fernandez	null	maria@correo.com	1.72	Maria	3156745
001	Castro	47	Pedrito123@gmail.com	1.57	Pedrito	null
003	null	null	manuela123@yahoo.com	null	Manuela	235644

CONSULTAS

{ }



()

CONSULTAS

Proyección. Un * indica que se devuelven todas las columnas.

SELECT id

FROM users

WHERE id='001'

ORDER BY nombre;

Tabla (familia de columnas)

consultada. Solo se puede consultar una tabla (no hay JOINS).

Criterios de búsqueda a cumplir. En el WHERE, sólo se pueden utilizar columnas que **formen parte de la partition key** o sobre las que se haya definido un índice secundario. Si la partition key es compuesta y se incluye en el WHERE, han de incluirse todos sus campos.

Criterios de ordenamiento. Siempre han de ser sobre columnas que estén incluidas en la clustering key.).

CONSULTAS

1. **SELECT** firstname **FROM** users **WHERE** id IN ('001','002');

```
cqlsh:prueba> SELECT nombre FROM usuarios WHERE id IN ('001','002');  
  
nombre  
-----  
Pedrito  
Maria
```

2. **SELECT** phone **FROM** users **WHERE** id = '003';

```
cqlsh:prueba> SELECT phone FROM users WHERE id = '012';  
  
phone  
-----  
798221
```

3. **SELECT** firstname , email **FROM** users **WHERE** id = '003';

```
cqlsh:prueba> SELECT nombre, email FROM usuarios WHERE id = '003';  
  
nombre | email  
-----+-----  
Manuela | manuela123@yahoo.com
```

TALLER

1. Muestre los nombres de todos los usuarios.
2. Muestre los nombres y apellidos de los usuarios nacidos antes del año 1980.

No se puede mostrar la segunda consulta... claro year no es parte de la PRIMARY KEY

Probemos entonces con USERS_YEAR. Creen la tabla USERS_YEAR y carguen los datos.

¿Qué ocurre?

{ }

- Como tiene el mismo partition key se sobrescriben (upsert)

```
cqlsh:prueba> select * from users2;
```

year	email	firstname	height	id	lastname	phone
1972	Pedrito@hotmail.com	Pedrito	1.57	001	Castro	null
1978	null	Camila	null	004	null	324228
1980	manuela123@yahoo.com	Manuela	1.62	003	Rojas	null

(3 rows)

```
cqlsh:prueba> INSERT INTO users2(id, firstname, lastname, height, year, email)  
, 1980, 'maria@correo.com');  
cqlsh:prueba> select * from users2;
```

year	email	firstname	height	id	lastname	phone
1972	Pedrito@hotmail.com	Pedrito	1.57	001	Castro	null
1978	null	Camila	null	004	null	324228
1980	maria@correo.com	Maria	1.72	002	Fernandez	null

CONSULTAS

Qué resultado darían las siguientes consultas:

- `SELECT id FROM users_year
WHERE year = 1980;`
- `SELECT id FROM users_year
WHERE year = 1980 and id='003';`

CONSULTAS

Order by:

- Sólo puede utilizarse sobre la clustering key.
- Indispensable que las partition key aparezcan en la cláusula where.
- Sólo tiene sentido para ordenar particiones.

Limit:

- Número máximo de filas a retornar.

ALLOW FILTERING

- Puede utilizarse para realizar consultas en las que en el WHERE no haya condiciones en la partition key.
- No recomendado a menos que sea estrictamente necesario: acceso secuencial a los datos

CONSULTAS

Dada la definición de la tabla USERS3

```
CREATE TABLE users3 (  
    id text,  
    firstname text,  
    lastname text,  
    year int,  
    height float,  
    phone int,  
    email text,  
  
    PRIMARY KEY ((id, year), lastname));
```

Qué resultado darían las siguientes consultas:

- `SELECT id FROM users3
WHERE year = 1980;`
- `SELECT id FROM users3
WHERE year = 1980 and id='003';`

CONSULTAS

Dada la definición de la tabla USERS

```
CREATE TABLE users4 (  
    id text,  
    firstname text,  
    lastname text,  
    year int,  
    height float,  
    phone int,  
    email text,  
  
    PRIMARY KEY ( year, lastname));
```


Qué resultado darían las siguientes consultas:

- `SELECT id FROM users4
WHERE year >1980;`
- `SELECT id FROM users4
WHERE year =1980;`

Muestre el id y el apellido de los usuarios de 1980 ordenados por el apellido

COLECCIONES

COLLECTION DATA TYPE



Restricciones: https://docs.datastax.com/en/cql-oss/3.3/cql/cql_using/useCollections.html

LIST

- Los valores se almacenan en forma de lista.
- Un valor puede almacenarse varias veces.
- El orden de la lista no se puede cambiar.

```
CREATE TABLE <table name>(  
column1 PRIMARY KEY,  
column2 list <data type>,  
column3 list <data type>,  
.....  
);
```

EJEMPLO

CREATE TABLE student

(EN int,

NAME text,

EMAIL LIST<text>,

PRIMARY KEY(EN),

);

INSERT INTO student (EN, NAME, EMAIL) VALUES(001,'Andres',['ayush@gmail.com']);

INSERT INTO student (EN, NAME, EMAIL) VALUES(002,'Lucia',['aarav@ymail.com']);

INSERT INTO student (EN, NAME, EMAIL) VALUES(003,'Carlos',['kabir@hotmail.com']);

UPDATE student

SET EMAIL=EMAIL+['ayush@hotmail.com']

where EN=001;

en	email	name
1	['ayush@gmail.com', 'ayush@hotmail.com']	Andres
2	['aarav@ymail.com']	Lucia
3	['kabir@hotmail.com']	Carlos

SET

- Consiste en un grupo de elementos con valores únicos.
- Los elementos del conjunto vuelven en orden después de la ejecución.

```
CREATE TABLE<table name> (  
column1 PRIMARY KEY,  
column2 set <data type>,  
column3 set <data type>  
.....  
);
```

EJEMPLO

Modifique la tabla STUDENT, adicione el atributo: `BRANCH` de tipo `SET<text>`

```
INSERT INTO student (EN, NAME, BRANCH) VALUES(004,'Alejandro',{'electrical engineering'});  
INSERT INTO student (EN, NAME, BRANCH) VALUES(005,'Adriana',{'Computer engineering'});  
INSERT INTO student (EN, NAME, BRANCH) VALUES(006,'Fabian',{'Applied Physics'});
```

```
UPDATE student  
SET BRANCH=BRANCH+{'Electrical and Electronics'}  
where EN=005;
```

Adicione además 'Architect' y 'Zoo', para ver el orden en que quedan almacenados. E ingrese nuevamente 'Zoo' (se ingresa nuevamente?)

MAP

- Se almacena un par de elementos clave-valor.
- Para cada clave, sólo puede existir un valor y no se pueden almacenar duplicados. Tanto la clave como el valor se designan con un tipo de datos.
- Con el tipo de mapa, puede almacenar información relacionada con la marca de tiempo en los perfiles de usuario.
- Cada elemento del mapa se almacena internamente como una columna de Cassandra que puede modificar, reemplazar, eliminar y consultar.
- Cada elemento puede tener un tiempo de vida individual y vencer cuando finaliza el TTL.

```
CREATE TABLE<table name>
(column1 PRIMARY KEY,
column2 map <type, data type>, column3 map
<type, data type>
.....
);
```

EJEMPLO

Modifique la tabla STUDENT, adicione el atributo `SUBJECT MAP<text, text>`

```
INSERT INTO student (EN, SUBJECT) VALUES (007, {'physics': 'mathematics'});
```

```
INSERT INTO student (EN, SUBJECT) VALUES (008, {'operating system': 'robotics'});
```

```
INSERT INTO student (EN, SUBJECT) VALUES (009, {'power system': 'machines'});
```

[]

{ }

[]

BORRAR FILAS DE LA TABLA

Ejemplo:

1. **DELETE FROM** users **WHERE** id = '002';

```
cqlsh:prueba> select * from users;
```

id	email	firstname	height	lastname	phone	year
004	null	Camila	null	null	324228	1978
002	maria@correo.com	Maria	1.72	Fernandez	null	1980
001	Pedrito123@gmail.com	Pedrito	1.57	Castro	null	1972
003	manuela123@yahoo.com	Manuela	1.62	Rojas	null	1980

```
(4 rows)
cqlsh:prueba> delete from users where id='002';
cqlsh:prueba> select * from users;
```

id	email	firstname	height	lastname	phone	year
004	null	Camila	null	null	324228	1978
001	Pedrito123@gmail.com	Pedrito	1.57	Castro	null	1972
003	manuela123@yahoo.com	Manuela	1.62	Rojas	null	1980

```
(3 rows)
cqlsh:prueba>
```

REFERENCIAS

- Bases de datos orientado a columnas. Adrian Garcete. Universidad Católica.
<http://jeuazaru.com/wp-content/uploads/2014/10/dbco.pdf>
- La información de Cassandra, tomada de: NoSQL: la siguiente generación de bases de datos.
Dr. Diego Lz. de Ipiña Glz. de Artaza. DeustoTech
<http://eventos.citius.usc.es/bigdata/>
- Cassandra
<http://cassandra.apache.org>
- Getting started with CQL:
http://www.datastax.com/docs/0.8/dml/using_cql
- Modelo de datos Cassandra
<https://sites.google.com/site/uegoman/modelo-de-datos-de-cassandra>
- Academy Datastax
<https://academy.datastax.com/#/catalog/c5b626ca-d619-45b3-adf2-a7d2b940a7ee>